ESTUDO COMPARATIVO DE ARQUITETURA & CIÊNCIA DE DADOS

Machine Learning no Octógono vs. Machine Learning no Banco

Como os mesmos princípios matemáticos do algoritmo de predição do UFC regem os modelos de Credit Scoring, Detecção de Fraudes e Gestão de Risco em grandes instituições financeiras (Fintechs e Bancos Tradicionais).

Domínio A: Previsão Esportiva (UFC Matchups)	**Domínio B:** Risco de Crédito & FinTech (Credit Scoring)
Algoritmo Comum: XGBoost + Platt Scaling	**Metodologia Comum:** Validação Temporal Cega (Out-of-Time)

1. A Tese Central: Por que o XGBoost Domina Ambos os Mundos?

Muitos imaginam que bancos e fintechs como Nubank, Itaú ou JPMorgan utilizam inteligências artificiais místicas ou redes neurais hipercomplexas para analisar crédito. Na prática corporativa, **mais de 90% dos modelos de risco de crédito, detecção de fraude e churn são baseados exatamente no algoritmo que usamos neste projeto: XGBoost / Gradient Boosted Decision Trees**.

A razão para isso é tripla: (1) Dados de clientes e lutas são tabulares e heterogêneos (misturam medidas contínuas, inteiros e taxas); (2) Árvores de decisão capturam interações não-lineares automaticamente sem precisar de transformações manuais complexas; e (3) Modelos baseados em árvores são auditáveis e permitem extrair a importância exata de cada atributo para atender exigências regulatórias (como LGPD e Banco Central).

2. O 'De-Para' Arquitetural: UFC vs. Banco

Abaixo está o mapeamento conceitual direto entre os dois universos:

Conceito de Machine Learning	No Modelo do UFC (Nosso Projeto)	No Modelo de Crédito Bancário (Fintech/Banco)
Alvo Preditivo (Target y)	O Lutador A vence o combate? **1 = Vitória / 0 = Derrota**	O cliente pagará a fatura em 90 dias? **1 = Bom Pagador / 0 = Inadimplência (Default)**
Histórico de Treino (Passado)	11.441 lutas cronológicas realizadas entre 1993 e 2022.	5 a 10 milhões de contratos de crédito concedidos nos últimos 3 a 5 anos.
Conjunto de Teste (Futuro)	2.143 lutas realizadas de 2023 a 2026 (Out-of-Time).	Safras de clientes que pegaram crédito nos últimos 12 meses (Safra Cega).
Variáveis Cadastrais / Perfil	Altura, peso, alcance, categoria de peso oficial.	Idade, renda declarada, estado civil, escolaridade, CEP.
Variáveis de Comportamento	Volume de socos/min, defesa de quedas, absorção de dano.	Histórico de atrasos de fatura, uso do limite, transações Pix, investimentos.
Variável Dinâmica Cumulativa	**Rating Elo Histórico** (calculado luta a luta).	**Internal Behavior Score** / Score Serasa (recalculado mês a mês).
Métrica de Momentum	**Streak Atual** (+5 vitórias ou -2 derrotas seguidas).	**Pontualidade Recente** (pagou as últimas 6 faturas em dia sem atraso).
Saída Matemática (Score)	Probabilidade calibrada: *'67.1% de chance de vitória'*.	Score de Risco (PD): *'Probabilidade de Calote: 3.2%'*.
Decisão de Negócio	Apostar / Selecionar favorito no fantasy game.	Aprovar empréstimo de R$ 15.000 ou liberar limite no cartão.

3. Feature Engineering: O 'Elo' vs. o 'Score de Comportamento'

Um dos passos mais importantes que realizamos no modelo do UFC foi a injeção do **Rating Elo** como atributo de treino. Nos bancos, isso se chama **Behavior Score** (Score Comportamental Interno):

- **No UFC:** Se Carlos Prates vence um adversário fraco, seu Elo sobe apenas 4 pontos. Se vence um ex-campeão ranqueado, seu Elo salta 28 pontos. O Elo resume em um único número a qualidade do histórico do lutador.
- **No Banco:** Se um cliente ganha R$ 20.000 mas estoura o cheque especial todo mês, seu Behavior Score desaba. Se um autônomo ganha R$ 3.000 mas nunca atrasou uma conta de luz em 4 anos, seu Behavior Score é altíssimo. Ambos os modelos usam uma variável temporal agregada para capturar o momento e a solidez do indivíduo.

4. Por que a Calibração de Probabilidades Salva um Banco da Falência?

No arquivo MODEL_OVERCONFIDENCE.md diagnosticamos que o XGBoost sem calibração cravava certezas de 90%+ para quase tudo. Aplicamos o **Platt Scaling (CalibratedClassifierCV)** para forçar o modelo a falar a verdade probabilística. Veja por que isso é a vida ou a morte de uma instituição financeira:

Nos bancos, a taxa de juros cobrada de um cliente é calculada diretamente pela fórmula da Perda Esperada: **Perda Esperada (EL) = Probabilidade de Calote (PD) * Exposição no Default (EAD) * Perda Dado o Default (LGD)**.

Se o modelo do banco for hiperconfiante e disser que a probabilidade de calote de um grupo de clientes é de **1%**, mas na realidade for de **8%**, o banco cobrará uma taxa de juros muito barata, emprestará bilhões de reais e entrará em insolvência quando os calotes reais chegarem. A calibração de probabilidade é a ferramenta matemática que garante que 5% de risco signifique exatamente 5 calotes em cada 100 clientes.

5. Regras de Negócio e o Paradoxo dos Outliers

Quando discutimos o caso de **Alex Pereira (39 anos)** e **Alexander Volkanovski (38 anos)**, descobrimos que colocar a idade pura no modelo tornava o algoritmo 'etarista', rebaixando lendas do esporte para a vala comum dos lutadores medianos.

Nos bancos, acontece exatamente a mesma coisa, mas com amparo legal e regulatório:

- **Compliance e Leis Anti-Discriminação:** Bancos são proibidos por lei de usar variáveis como raça, religião ou gênero, e existem regras estritas sobre o uso da idade para que idosos ou jovens não sejam negados sumariamente apenas pela faixa etária.
- **Regras de Política de Crédito (Hard Rules):** Assim como no UFC criamos a função *weight_classes_compatible* para impedir que um peso-mosca lute com um peso-pesado, bancos têm 'regras de esteira' antes do modelo de IA rodar (ex: se o cliente tiver nome negativado com mais de 5 protestos judiciais, ele é barrado pela política antes mesmo do XGBoost ser acionado).

6. Como os Bancos Mantêm seus Modelos Vivos (Data Drift)

Você perguntou como se treinam novos dados: no nosso projeto, quando o dono do Kaggle atualizou para 2026, criamos o script *update_dataset_2026.py* e retreinamos o XGBoost. No setor bancário, isso é chamado de **Monitoramento de Data Drift e Concept Drift**:

- **No UFC:** O esporte muda. O estilo de luta dominante em 2026 envolve muito mais trocação defensiva e grade do que o jiu-jitsu tradicional de 1995.
- **No Banco:** A economia muda. Um cliente que era 'baixo risco' com taxa de juros Selic a 2% ao ano pode virar 'alto risco' quando a Selic sobe para 14% ao ano. Por isso, os bancos rodam pipelines automáticos mensais (usando ferramentas como Airflow e Kubeflow) para retreinar seus modelos com a safra mais recente de dados.

7. Conclusão: A Transferência de Habilidade

Ao construir e entender este sistema de predição do UFC — dominando a **divisão temporal cega (Out-of-Time)**, a **engenharia de atributos sequencial sem vazamento (Elo e Streaks)**, o **treinamento do XGBoost com regularização** e a **calibração sigmoidal de probabilidades** —, você dominou exatamente o mesmo ferramental técnico, matemático e conceitual exigido para construir modelos de risco em fintechs de ponta e nos maiores bancos do planeta.